

Comparación de Arquitecturas de Segmentación para la Estimación de Áreas de Daño en Vehículos

Santiago Bartolini Rizzo
CEIA - Visión por Computadora II
FIUBA
Buenos Aires, Argentina
santiagobartolini@gmail.com

Luis Ali
CEIA - Visión por Computadora II
FIUBA
Buenos Aires, Argentina
aliluis@gmail.com

Eliana Harriet
CEIA - Visión por Computadora II
FIUBA
Buenos Aires, Argentina
eharriet@fi.uba.ar

Resumen—Se comparan dos paradigmas de segmentación para estimar áreas de daño en vehículos: segmentación por instancias (YOLOv8-seg) y semántica (U-Net). Se utiliza un único dataset de 2.320 imágenes con 4 clases de daño, convertido a ambos formatos para que la única variable sea la arquitectura. Sobre el subconjunto común de 89 imágenes de test (de un total de 119) la U-Net alcanza un IoU binario pareado mayor (0.6605 frente a 0.6061) y un error de área relativo sustancialmente menor en media sobre sus respectivos conjuntos completos (0.450 frente a 0.870).

La diferencia pareada de IoU es estadísticamente significativa ($p = 0.029$), lo que refuta la hipótesis *H1*: el enfoque por instancias no estima el área de daño con mayor precisión.

Index Terms—YOLOv8-seg; U-Net; segmentación de instancias; segmentación semántica; estimación de área de daño; evaluación de modelos

I. INTRODUCCIÓN

La detección y cuantificación del daño en vehículos es una tarea relevante para la industria aseguradora y de alquiler de vehículos, donde el área afectada es la entrada clave para la cotización de reparaciones. La segmentación de imágenes, al localizar píxel a píxel las regiones dañadas, permite cuantificar el daño con precisión y supera las limitaciones de las cajas delimitadoras (bounding boxes), que incluyen zonas sanas y no reflejan la forma real del daño.

La demanda de estos sistemas ya es un caso real de industria: una empresa española de peritaje de siniestros, junto a investigadores universitarios, desarrolló un sistema de inspección automática de daños sobre un ensamble de detectores YOLOv5/YOLOv8 entrenado con imágenes anotadas por peritos profesionales de seguros [8]. El sistema estima automáticamente la localización y severidad del daño, reduce las pérdidas por reclamos mal valuados y publicó su dataset como referencia abierta. Ese antecedente, como el presente trabajo, opera sobre fotografías de siniestros reales; a diferencia de él (que resuelve detección), aquí se enfrentan los dos paradigmas de segmentación para cuantificar el área dañada.

Dentro del aprendizaje profundo, la segmentación de imágenes se aborda desde dos paradigmas complementarios [5]: la segmentación por *instancias*, que detecta y delimita cada objeto dañado por separado, y la segmentación *semántica*, que clasifica cada píxel en una clase. Estos enfoques difieren en su

representación y en el incentivo que recibe el modelo durante el entrenamiento, lo que puede traducirse en diferencias en la precisión de los contornos y, en consecuencia, en la estimación del área. Frente a esta pregunta no es evidente *a priori* cuál de los dos paradigmas estima el área de daño con mayor exactitud.

El objetivo de este trabajo es determinarlo empíricamente. A diferencia de estudios que comparan modelos entrenados sobre conjuntos de datos distintos, aquí se emplea un único *dataset*, *Car Damages* (2.320 imágenes, 4 clases de daño), convertido a los dos formatos requeridos por cada paradigma: la única variable de la comparación es la arquitectura del modelo. Se entrena un detector de instancias basado en YOLOv8-seg [4] y un segmentador semántico basado en U-Net [2], se aplanan las predicciones de instancias en una máscara única para hacerlas comparables y se confrontan ambas salidas mediante métricas binarias y multiclase, complementadas con un análisis estadístico pareado. Con este diseño, que optimiza los contornos de objetos individuales, se somete a verificación la siguiente hipótesis:

H1: el enfoque por instancias produce estimaciones de área de daño más exactas que la segmentación semántica. La hipótesis es plausible *a priori* porque el entrenamiento por instancias no penaliza los píxeles de fondo y porque la conversión a máscara semántica de sus predicciones “aplanadas” conserva la información de contorno de cada objeto dañado; véase la Sección IV-E para su verificación.

II. TRABAJO RELACIONADO

La estimación automática de daños en vehículos es un problema de fuerte interés industrial [8]. Dentro del aprendizaje profundo, la segmentación por *instancias* detecta y delimita cada objeto dañado por separado mediante detectores como YOLOv8-seg [4], apoyados en redes *backbone* residuales [3]; la segmentación *semántica*, en cambio, clasifica cada píxel en una clase con arquitecturas como U-Net [2], V-Net [7] o DeepLabV3+ [6]. Ambos paradigmas conviven en la segmentación *panóptica* [5], que unifica objetos e instancias en una única representación. No obstante, la mayoría de los estudios compara modelos entrenados sobre conjuntos de datos independientes, mezclando la influencia de la arquitectura con

la de los datos; el presente trabajo aísla esa variable al convertir una misma fuente de anotaciones a ambos formatos.

III. METODOLOGÍA

III-A. Dataset

Se utilizó el dataset *Car Damages* (Dataset A) [1], publicado en Roboflow [1], compuesto por 2.320 imágenes divididas en 1.970 de entrenamiento, 231 de validación y 119 de test. El dataset está anotado en formato de segmentación semántica, pero sus anotaciones son polígonos que delimitan cada objeto dañado por separado, lo que habilita su conversión a ambos formatos. Las imágenes provienen de vehículos anotados con cuatro clases de daño:

- **Minor Damage (Dent):** abolladuras leves.
- **Minor Damage (Scratch):** rayones superficiales.
- **No Damage:** vehículos sin daños visibles.
- **Severe Damage:** daños severos o graves.

que, junto con el fondo, conforman un espacio de etiquetas de cinco clases. La Tabla I resume el reparto de imágenes por partición.

La decisión metodológica central del trabajo es que ambos modelos se entrenaron a partir de **la misma fuente de anotaciones**: el dataset en formato COCO se convirtió de forma automática a dos representaciones paralelas, polígonos en formato YOLO para la segmentación por instancias y máscaras rasterizadas PNG para la segmentación semántica. Ambos árboles de datos contienen exactamente las mismas imágenes, los mismos splits y las mismas anotaciones; solo difiere la representación. De este modo, la única variable independiente del experimento es la arquitectura del modelo, lo que hace válida la comparación entre paradigmas.

Tabla I
REPARTO DE IMÁGENES DEL DATASET CAR DAMAGES.

Participación	Imágenes
Entrenamiento	1.970
Validación	231
Test	119
Total	2.320

III-B. Preparación de datos

El dataset se anota en formato de segmentación semántica, pero las anotaciones son polígonos que delimitan cada objeto dañado por separado (formato COCO Segmentation). Un DAG de preparación de datos en Airflow (`data_preparation_semantic`) descarga este formato COCO y lo convierte automáticamente a los dos formatos requeridos por cada modelo:

- **Instance:** las coordenadas de los polígonos se exportan a archivos de etiquetas YOLOv8, uno por imagen, junto con las imágenes originales.
- **Semantic:** los polígonos se rasterizan en máscaras PNG donde cada píxel codifica el identificador de clase de daño.

La Fig. 1 esquematiza esta conversión. En ambos formatos se conservan exactamente las mismas imágenes y anotaciones: solo cambia la representación. Esto garantiza que ambos modelos entrenen sobre los mismos datos y que la única variable de la comparación sea la arquitectura.




Figura 1. Conversión de las anotaciones COCO a los dos formatos de entrenamiento.

III-C. Modelos

Como representante del paradigma de instancias se eligió YOLOv8-seg [4]: resuelve detección y máscara en una sola pasada, parte de pesos preentrenados en COCO, ofrece tiempos de entrenamiento e inferencia reducidos y produce instancias separadas, lo que habilita contar daños individuales. Se descartó Mask R-CNN por su mayor costo de GPU y menor velocidad para el mismo volumen de datos, sin aportar a la pregunta de investigación.

Como representante del paradigma semántico se eligió U-Net [2] con un encoder ResNet50 [3] preentrenado en ImageNet: es la arquitectura encoder-decoder con *skip connections* estándar para segmentación densa con datasets de tamaño moderado. Se descartó DeepLabV3+ [6] por su mayor costo computacional, que tampoco aportaba a la comparación planteada.

Dado que el fondo ocupa aproximadamente el 80% de los píxeles y domina el gradiente, U-Net se entrenó con una pérdida Dice [7] ponderada por clase, con pesos calibrados empíricamente ([0,057, 0,207, 0,286, 0,253, 0,197] para fondo, Dent, Scratch, No Damage y Severe, respectivamente) que reducen el peso del fondo a favor de las clases de daño minoritarias.

La Tabla II resume la configuración de ambos entrenamientos. Épocas máximas, paciencia del *early stopping*, resolución de entrada y semilla se igualaron deliberadamente para aislar el efecto de la arquitectura; el tamaño de batch difiere porque U-Net con ResNet50 a resolución 640×640 no entra en memoria de GPU con batch 16.

Nótese la asimetría en el número de clases: la U-Net predice cinco clases (fondo más las cuatro de daño), mientras que

Tabla II
CONFIGURACIÓN DE ENTRENAMIENTO DE AMBOS MODELOS

	YOLOv8-seg	U-Net
Backbone / pesos	yolov8x-seg (COCO)	ResNet50 (ImageNet)
Épocas (máx.)	150	150
Early stopping (patience)	20	20
Batch size	16	8
Resolución	640 × 640	640 × 640
Learning rate	scheduler Ultralytics	10 ⁻⁴ (Adam)
Semilla	2026	2026
Clases	4 (+fondo implícito)	5 (fondo explícito)

YOLOv8-seg opera solo sobre las cuatro clases de daño. Como se describe en la siguiente subsección, la comparación de salidas se alinea sobre una máscara de daño común, de modo que esta diferencia no afecta la comparabilidad.

III-D. Métricas y análisis pareado

Para poder comparar salidas de naturaleza distinta, las predicciones de instancias de YOLOv8-seg se *aplanan* en una máscara semántica única mediante una estrategia *class aware* por confianza: cada instancia detectada se pinta con su clase de daño (espacio de cinco etiquetas compartido, fondo = 0) y, cuando dos instancias se superponen, gana el píxel la de mayor confianza. Se consideraron alternativas como OR lógico, prioridad por confianza (cualquier clase) o última instancia en ganar, pero la estrategia *class aware* es la única que conserva la información de clase en las superposiciones, condición necesaria para la comparación multiclase.

Sobre las máscaras resultantes se calculan dos vistas de métricas: (i) una vista **binaria** daño/no-daño, en la que la clase *No Damage* se trata como fondo, con IoU, precisión, recall y F1; y (ii) una vista **multiclase macro** sobre las cinco clases, con pixel accuracy global e IoU por clase. Además se mide el error de área absoluto (en píxeles) y relativo respecto del área de daño del ground truth, que es la métrica alineada con el objetivo del caso de uso:

$$\text{Err}_{\text{area}} = \frac{|\hat{A} - A|}{A}, \quad (1)$$

donde A y $\hat{A}$ son las áreas de daño real y predicha en píxeles. El IoU binario se calcula sobre la máscara de daño y, si no hay daño ni en la referencia ni en la predicción (unión vacía), se puntúa con $\text{IoU} = 1$ en lugar de 0, para no castigar los casos correctos sin daño. Los IoU por clase se agregan micro-promediando sobre el conjunto de evaluación (TP, FP y FN acumulados por clase en todas las imágenes).

YOLOv8-seg produjo al menos una máscara en 89 de las 119 imágenes de test, mientras que U-Net produce una predicción densa en las 119. Para evitar el sesgo de selección que introduciría comparar conjuntos distintos, el análisis estadístico principal es **pareado sobre las 89 imágenes comunes**: se calcula la diferencia de IoU imagen a imagen y se estiman intervalos de confianza del 95 % mediante bootstrap de 1.000 remuestreos (semilla 2026), complementados con un t-test pareado, declarando significancia bajo $\alpha = 0,05$. El test

contrasta la hipótesis $H1$ planteada (Sección Introducción) y no su hipótesis nula de que la segmentación semántica sea superior.

III-E. Infraestructura y reproducibilidad

Todo el experimento se ejecuta como un pipeline orquestado con Apache Airflow, con DAGs encadenados de preparación de datos, entrenamiento y evaluación. El entrenamiento se despacha a workers GPU *serverless* de RunPod directamente desde el DAG; el seguimiento de experimentos y el versionado de modelos se realizan con MLflow (tracking y Model Registry), con artefactos en MinIO (S3 compatible) y metadatos en PostgreSQL desplegados en un VPS. Esta arquitectura hace que la comparación sea reproducible de punta a punta: volver a correr los DAGs con la misma semilla regenera datasets, entrenamientos y métricas.

IV. RESULTADOS

IV-A. Entrenamiento

YOLOv8-seg convergió en aproximadamente 110 épocas efectivas (early stopping con paciencia 20) y alcanzó, sobre validación, mAP50 de 0.5413 y mAP50-95 de 0.3567 en cajas, y mAP50 de 0.5176 y mAP50-95 de 0.2979 en máscaras, con precisión y recall de máscara de 0.6422 y 0.5215. La Fig. 2 muestra sus curvas de entrenamiento: las pérdidas descienden de forma estable y las métricas de validación se saturan hacia el final, sin señales de sobreajuste. U-Net convergió en aproximadamente 91 épocas efectivas, con una pérdida de validación (Dice ponderada) estable y un tiempo total de entrenamiento de 2.0 horas en GPU. Estos valores indican que ambos modelos alcanzaron un ajuste razonable y comparable antes de la evaluación conjunta.

IV-B. Comparación binaria

La Tabla III muestra las métricas binarias sobre el conjunto de test completo de cada modelo. Sobre los conjuntos completos, U-Net obtiene un IoU binario levemente superior (0.6200 frente a 0.6061) y mayor precisión, mientras que YOLOv8-seg conserva una ventaja clara en recall (+13.6 % relativo). Como se muestra en la Sección IV-E, el análisis pareado confirma que la diferencia de IoU es estadísticamente significativa a favor del modelo semántico.

Tabla III
MÉTRICAS BINARIAS (DAÑO VS. NO-DAÑO), TEST SET COMPLETO DE CADA MODELO

Métrica	YOLOv8-seg	U-Net	Δ
IoU (daño binario)	0.6061	0.6200	-0.0139
Precisión binaria	0.6280	0.6532	-0.0252
Recall binario	0.7305	0.6429	+0.0876
F1 binario	0.6309	0.6139	+0.0170




Figura 2. Curvas de entrenamiento de YOLOv8-seg: pérdidas de entrenamiento y validación (box, seg, cls, dfl) y métricas de validación (precisión, recall, mAP50 y mAP50-95, para cajas (B) y máscaras (M)).

IV-C. Comparación multiclase

La Tabla IV presenta las métricas macro sobre las cinco clases y los errores de área. Cabe aclarar que las precisiones y recalls de esta tabla son promedios macro multiclase y no son comparables con los valores binarios de la Tabla III. En las métricas macro ambos modelos son parejos (F1 macro de 0.3015 y 0.3150), con una ventaja consistente pero moderada de U-Net, que también obtiene mayor pixel accuracy (0.8851 frente a 0.8394). La diferencia decisiva aparece en el **error relativo de área**: U-Net comete un error medio del 45.0 % del área real de daño, frente al 87.0 % de YOLOv8-seg, es decir, casi la mitad. Cabe aclarar que estos errores se promedian sobre el conjunto completo evaluado por cada modelo (119 imágenes para U-Net y, como se detalla en la subsección siguiente, 89 para YOLOv8-seg), por lo que comparan poblaciones de distinto tamaño y *no* se someten a un test pareado: constituyen una evidencia descriptiva, mientras que la significancia estadística del informe se apoya en el IoU pareado. Dado que el objetivo del sistema es cuantificar el área dañada, esta métrica orienta la elección, aunque con el respaldo estadístico ya señalado.

Tabla IV
MÉTRICAS MULTICLASE (MACRO, 5 CLASES) Y ERROR DE ÁREA

Métrica	YOLOv8-seg	U-Net	Δ
Pixel accuracy (global)	0.8394	0.8851	−0.0458
Precisión (macro)	0.3127	0.3327	−0.0200
Recall (macro)	0.3149	0.3233	−0.0085
F1 (macro)	0.3015	0.3150	−0.0135
Error de área abs. (px)	31 592.9	18 116.7	+13 476.3
Error de área relativo	0.8704	0.4501	+0.4202

IV-D. IoU por clase

La Tabla V y la Fig. 3 desagregan el IoU por clase. U-Net supera al modelo por instancias en las clases con menos ejemplos: *No Damage* (0.5473 frente a 0.4363) y *Severe Damage* (0.5300 frente a 0.4100), además del fondo, mientras que YOLOv8-seg conserva una ventaja marginal en las dos

clases de daño leve, *Dent* (+0.0174) y *Scratch* (+0.0032). Este patrón sugiere que la predicción densa por píxel del modelo semántico aprovecha mejor las clases minoritarias — ayudada por la pérdida Dice ponderada —, mientras que el detector de instancias depende de proponer correctamente cada objeto, algo más difícil con pocos ejemplos de entrenamiento.

Tabla V
IoU POR CLASE (MICRO-PROMEDIO SOBRE EL TEST SET)

Clase	YOLOv8-seg	U-Net	Δ
Background	0.8362	0.8870	−0.0508
Minor Damage (Dent)	0.4126	0.3952	+0.0174
Minor Damage (Scratch)	0.5307	0.5276	+0.0032
No Damage	0.4363	0.5473	−0.1110
Severe Damage	0.4100	0.5300	−0.1200




Figura 3. IoU por clase de ambos modelos. U-Net domina en las clases minoritarias (No Damage y Severe Damage); YOLOv8-seg es marginalmente mejor en las clases de daño leve.

IV-E. Análisis estadístico

Sobre las 89 imágenes evaluadas por ambos modelos, el IoU medio pareado es 0.6061 para instancias y 0.6605 para semántica: una diferencia de −0.0544 (−8.23 %) a favor del modelo semántico. El bootstrap de 1.000 remuestrados (95 %, semilla 2026) arroja intervalos de confianza de [0,5450, 0,6641] para instancias y [0,6033, 0,7102] para

semántica, y un intervalo para la *diferencia media por imagen* de $[-0,1024, -0,0093]$, que **excluye al cero**. El t-test pareado confirma la significancia con $p = 0,0289$. Los desvíos estándar del IoU (0.2783 y 0.2915) muestran una variabilidad entre imágenes alta, pero aun así la diferencia resulta detectable. En consecuencia, la hipótesis *H1* de partida queda **refutada** con evidencia estadística: la ventaja esperada de los contornos por instancia no se materializa y el modelo semántico obtiene un IoU pareado significativamente mayor. El menor error de área del modelo semántico se presenta como evidencia descriptiva (sección comparación multiclase), no como resultado de un test pareado.

IV-F. Visualización cualitativa

La Fig. 4 compara, para las mismas imágenes de test, el ground truth con las predicciones de ambos modelos. Se observa el patrón que las métricas anticipan: YOLOv8-seg tiende a cubrir de más (consistente con su mayor recall, 0.7305, y su mayor error de área), mientras que U-Net produce máscaras más ajustadas al área real (mayor precisión, 0.6532, y casi la mitad de error relativo de área), a costa de omitir daños con algo más de frecuencia.




Figura 4. Comparación cualitativa sobre las mismas imágenes: original y ground truth (filas superiores), YOLOv8-seg aplanado (tercera fila) y U-Net (fila inferior).

V. DISCUSIÓN

Los resultados muestran que las predicciones del modelo semántico son más aptas para cuantificar el área de daño. La interpretación de estos resultados sugiere que la elección entre paradigmas depende del costo de negocio de cada tipo de error. Si el sistema debe *no dejar pasar daños* (inspección de flotas, triage de siniestros), el mayor recall y la capacidad de contar instancias de YOLOv8-seg lo favorecen. Si el sistema debe *cuantificar el área dañada* para valorizar una reparación, que es el objetivo planteado en este trabajo, el enfoque semántico

es preferible: obtiene un IoU pareado significativamente mayor y un error de área sustancialmente menor en media.

Cabe señalar, además, que el desbalance de clases penaliza más al detector de instancias: la U-Net, con su pérdida Dice ponderada, supera a YOLOv8-seg justamente en las clases con menos ejemplos, mientras que el detector solo conserva ventajas marginales en las clases de daño leve, más frecuentes. La variabilidad entre imágenes (desvíos estándar de aproximadamente 0.28) indica que el IoU individual fluctúa bastante, pero la diferencia pareada resulta igualmente detectable.

VI. CONCLUSIONES

Del trabajo se extraen las siguientes conclusiones.

Primera: en el análisis pareado sobre las 89 imágenes comunes, el modelo semántico segmenta el daño con un IoU significativamente mayor que el modelo por instancias aplanado (0.6605 frente a 0.6061; diferencia -0.0544 ; $p = 0,0289$; IC 95 % $[-0,1024, -0,0093]$, que excluye al cero).

Segunda: la hipótesis *H1* de partida queda refutada. Aplanar las instancias no mejora la estimación de área: en media sobre sus conjuntos completos, U-Net reduce el error relativo de área a casi la mitad (0.4501 frente a 0.8704). Siendo esa la métrica alineada con el caso de uso, el enfoque semántico es el indicado para cuantificar daño, con el respaldo estadístico del IoU pareado y el error de área como evidencia descriptiva (no testada pareado).

Tercera: los paradigmas fallan de forma distinta. El modelo por instancias favorece el recall (0.7305 frente a 0.6429) y permite contar daños individuales; el semántico favorece la precisión (0.6532 frente a 0.6280) y la fidelidad del área. La elección final depende del costo relativo de falsos positivos y falsos negativos en el negocio.

Cuarta: el desbalance de clases penaliza más al detector de instancias. U-Net, con la pérdida Dice ponderada, supera a YOLOv8-seg justamente en las clases con menos ejemplos — *No Damage* (0.5473 frente a 0.4363) y *Severe Damage* (0.5300 frente a 0.4100) —, mientras que el detector solo conserva ventajas marginales en las clases de daño leve, más frecuentes.

Quinta: las métricas macro multiclase (F1 de 0.3015 y 0.3150) sugieren que el cuello de botella real no es la arquitectura sino la granularidad de las etiquetas y el volumen de datos de las clases minoritarias.

Sexta: la orquestación con Airflow, MLflow y GPU serverless permitió una comparación controlada y reproducible (misma semilla, mismos splits, mismas épocas y misma fuente de anotaciones), y el esquema es directamente transferible a la comparación de otros pares de arquitecturas.

Como trabajo futuro se propone ampliar los datos de las clases minoritarias, unificar *Dent* y *Scratch* en una única clase de daño leve, evaluar arquitecturas alternativas como DeepLabV3+ [6] y Mask R-CNN, y medir la latencia de inferencia de ambos modelos en el mismo hardware de cara al despliegue productivo.

REFERENCIAS

- [1] Roboflow Universe, “Car Damages Dataset,” accessed Aug. 14, 2026. [Online]. Available: <https://universe.roboflow.com/project-p5nyc/car-damages-v3gyz>
- [2] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” in Proc. Medical Image Computing and Computer-Assisted Intervention (MICCAI), Munich, Germany, 2015, pp. 234–241.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 770–778.
- [4] Ultralytics, “YOLOv8 — Instance segmentation,” Ultralytics Documentation. [Online]. Available: <https://docs.ultralytics.com/tasks/segment/>. [Accessed: Aug. 14, 2026].
- [5] A. Kirillov, K. He, R. Girshick, C. Rother, and P. Dollár, “Panoptic segmentation,” in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019, pp. 9404–9413.
- [6] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, “Encoder-decoder with atrous separable convolution for semantic image segmentation,” in Proc. European Conf. Computer Vision (ECCV), Munich, Germany, 2018, pp. 801–818.
- [7] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-Net: Fully convolutional neural networks for volumetric medical image segmentation,” in Proc. Int. Conf. 3D Vision (3DV), Stanford, CA, USA, 2016, pp. 565–571.
- [8] S. A. Pérez-Zarate, D. Corzo-García, J. L. Pro-Martín, J. A. Álvarez-García, M. A. Martínez-del-Amor, and D. Fernández-Cabrera, “Automated car damage assessment using computer vision: insurance company use case,” *Applied Sciences*, vol. 14, no. 20, p. 9560, 2024, doi: 10.3390/app14209560.